Raciocínio Probabilístico

Prof. Dr. Hendrik Macedo
Departamento de Computação

A máquina deduz, mas faz isso considerando suas crenças sobre o mundo e não certezas sobre o mundo

O mundo real é Incerto

- Os primeiros sistemas de IA eram baseados em lógica simbólica formal.
  - Uma proposição é estritamente **verdadeira** ou **falsa**.
  - Isso assume um mundo perfeitamente observável e previsível.
- O mundo real, no entanto, é cheio de **incerteza**.
  - Informações incompletas.
  - Dados ruidosos (e.g., de sensores).
  - Conhecimento impreciso.
  - Aleatoriedade intrínseca.
- Para tomar decisões inteligentes, a IA precisa de uma linguagem para **representar e manipular a incerteza**.

Raciocínio Probabilístico em IA

- A **Teoria da Probabilidade** fornece a linguagem para lidar com a incerteza
- A probabilidade é o **grau de crença** de um agente em uma proposição, dadas as evidências.
- Isso permite que um agente **atualize suas crenças** de forma racional à medida que novas informações são adquiridas.
  - Começa com uma crença **a priori**.
  - Observa evidências.
  - Calcula uma crença **a posteriori**.

O que são Redes Bayesianas?

- Um modelo gráfico probabilístico para **representar conhecimento em um domínio incerto**.
  - Desenvolvidas e popularizadas nos anos 1980.
- Modelo híbrido, que combina duas partes:
  - **Componente Qualitativo (Estrutura):** Um **Grafo Acíclico Dirigido (DAG)** que representa as relações de dependência entre variáveis.
  - **Componente Quantitativo (Parâmetros):** Um conjunto de **Tabelas de Probabilidade Condicional (CPTs)** que quantifica a força dessas relações.

DAG

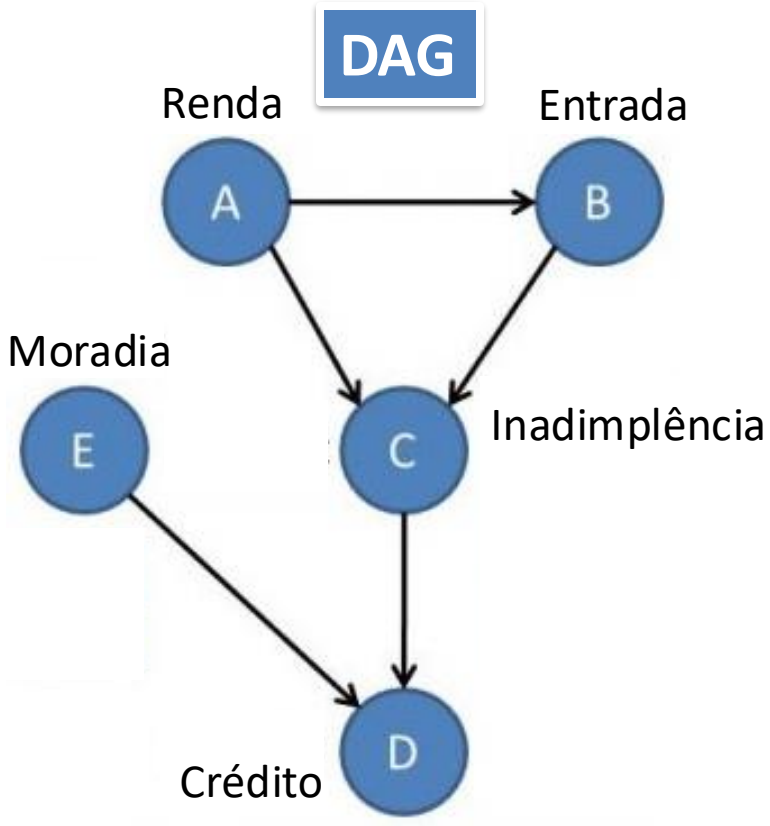

- Exemplo: **Risco de crédito**
- Modela a probabilidade de alguém se tornar inadimplente e de algum crédito ser concedido, com base nas finanças:
  - **Renda:** alta, baixa
  - **Entrada**: grande, pequeno
  - **Moradia**: casa própria, aluguel
  - **Inadimplente**: sim, não
  - **Crédito**: sim, não

DAG

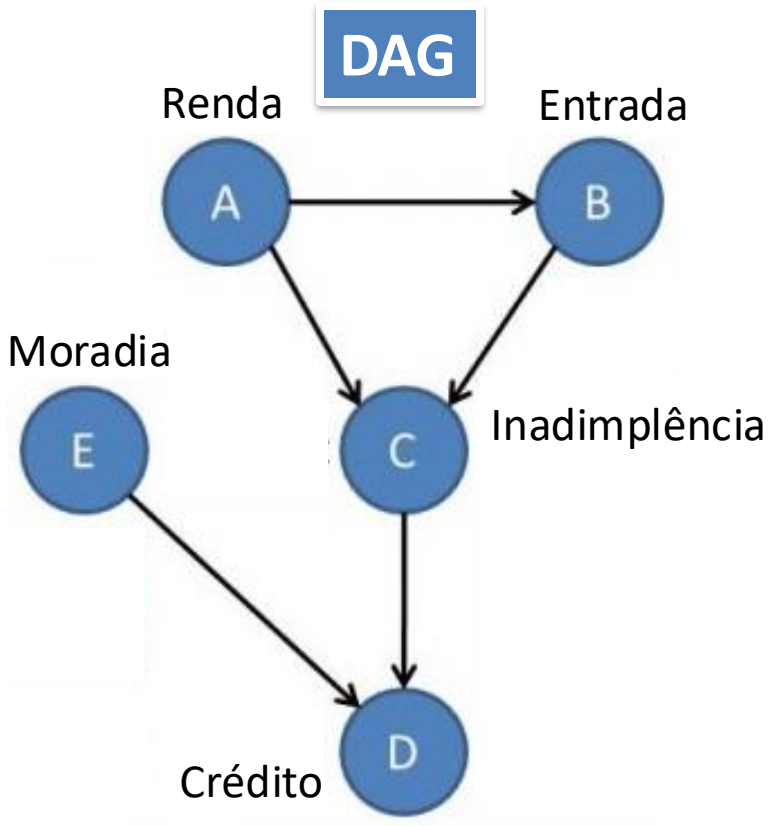

- Cada nó representa uma **variável aleatória**
  - **Variáveis Observadas:** evidências que o agente usa para atualizar suas crenças
  - **Variáveis Latentes:** não são observáveis diretamente, mas inferidas pelo agente
- Qualquer variável pode ser observada ou latente, dependendo do problema que o agente está tentando resolver.
- As arestas são dirigidas (setas) e indicam **influência direta** entre variáveis

CPT

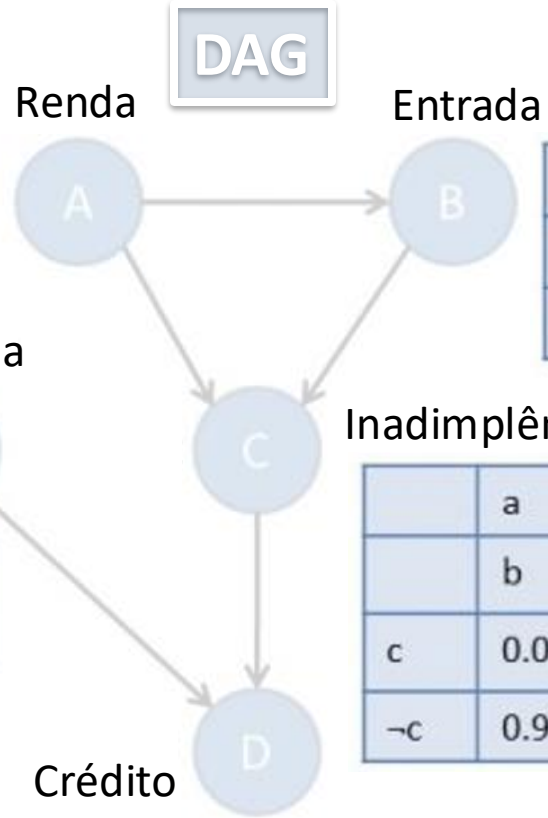

CPTs

a	0.3
¬a	0.7

	a	¬a
b	0.9	0.4
¬b	0.1	0.6

e	0.35
¬e	0.65

	a		¬a	
	b	**¬b**	b	¬b
c	0.05	**0.5**	0.45	0.6
¬c	0.95	**0.5**	0.55	0.4

	c		¬c	
	e	¬e	e	¬e
d	0.01	0.5	0.75	0.31
¬d	**0.99**	0.5	**0.25**	0.69

- **Distribuições de Probabilidade a Priori:** crença estática do modelo sobre essas variáveis, $P(X)$
  - Renda e Moradia
- **Distribuições de Probabilidade Condicional:** crença estática do modelo s/ cada combinação de valores de seus pais, $P(X|Pais(X))$
  - Entrada, Inadimplência e Crédito

Leituras direta das CPTs para o exemplo

- $P(A)$:
  - A probabilidade de alguém ter Renda Alta (a) é 30% ($P(a) = 0.3$).
  - A probabilidade de ter Renda Baixa (¬a) é 70% ($P(\neg a) = 0.7$).
- $P(E)$:
  - A probabilidade de alguém ter casa própria (e) é 35% ($P(e) = 0.35$).
  - A probabilidade de ser Inquilino (¬e) é 65% ($P(\neg e) = 0.65$).
- $P(B|A)$ (Entrada dado Renda):
  - Se a Renda é Alta (a), a chance de ter uma Entrada Grande (b) é 90% ($P(b|a) = 0.9$).
  - Se a Renda é Baixa (¬a), a chance de ter uma Entrada Grande (b) é 40% ($P(b|\neg a) = 0.4$).
- $P(C|A,B)$ (Inadimplência dado Renda e Entrada):
  - $P(c \mid a, \neg b) = 0.5$: "A probabilidade de se tornar Inadimplente (c), DADO que a Renda é Alta (a) E a Entrada é Pequena (¬b), é de 50%."
  - $P(c \mid a, b) = 0.05$: "Se a Renda é Alta (a) E a Entrada é Grande (b), a chance de Inadimplência (c) cai para 5%."
- $P(D|C,E)$ (Crédito dado Pagamento e Moradia):
  - $P(\neg d \mid c, e) = 0.99$: "A probabilidade de NÃO ter crédito (¬d), DADO que é Inadimplente (c) E possui Imóvel próprio (e), é de 99%." (Faz sentido).
  - $P(\neg d \mid \neg c, e) = 0.25$: "A probabilidade de NÃO ter crédito (¬d), DADO que é Adimplente (¬c) E possui Imóvel próprio (e), é de 25%." (O que implica que a chance de ter crédito, $P(d|\neg c, e)$, é de 75%).

Pra que serve isso tudo de fato?

- Usando uma BN e as regras de probabilidade, podemos fazer pelo menos dois tipos de **inferências** complexas:
  - **Previsão:** *"Qual a probabilidade de um novo cliente, que tem Renda Baixa (¬a) e é Inquilino (¬e), se tornar Inadimplente (c)?"*

$$P(c|\neg a, \neg e) = ?$$

  - **Diagnóstico:** *"Um cliente se tornou Inadimplente (c). Qual a probabilidade de que ele tivesse Renda Baixa (¬a)?"*

$$P(\neg a \mid c) = ?$$

Matemática por trás do modelo

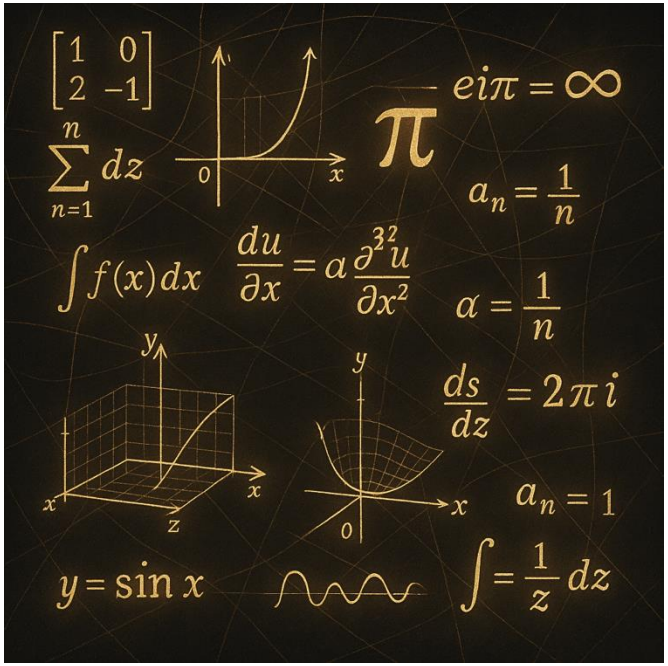

Base Matemática: Teorema de Bayes

- O **Teorema de Bayes** é a base do **motor da inferência** e do aprendizado em BNs, que nos permite **atualizar as crenças** (probabilidades) à luz de novas evidências.

$$P(H|E) = \frac{P(E|H) \cdot P(H)}{P(E)}$$

- Onde:
  - $P(H|E)$ é a **probabilidade a posteriori** (o que queremos saber).
  - $P(E|H)$ é a **verossimilhança** (como a hipótese explica a evidência).
  - $P(H)$ é a **probabilidade a priori** (nossa crença inicial).
  - $P(E)$ é a **evidência marginal** (um fator de normalização).

Semântica: Fatoração da Probabilidade Conjunta

- A regra da cadeia da probabilidade diz:

$$P(X_1, \dots, X_n) = P(X_{n-1}, \dots, X_1)\, P(X_{n-1} | X_{n-2}, \dots, X_1) \dots P(X_2 | X_1)\, P(X_1)$$

  – Isso é complexo e requer um número exponencial de parâmetros.
- A estrutura do DAG em uma BN impõe uma **Cobertura de Markov Local**: um nó é condicionalmente independente de seus não-descendentes, dados seus pais.
- Isso simplifica drasticamente a regra da cadeia:

$$\mathrm{P}(X_1, \dots, X_n) = \prod_{i=1}^{n} P(X_i | \mathrm{Pais}(X_i))$$

  – A distribuição conjunta global é um produto de probabilidades locais (as CPTs).

Independência Condicional: *d-separation*

- Detalhando um pouco mais o entendimento da cobertura de Markov...
- Como podemos saber se um conjunto de nós X é independente de Y, dado um conjunto de evidências Z, apenas olhando para o grafo?
- X e Y são **d-separados** por Z se **todos os caminhos** entre eles estiverem "bloqueados"

Cadeias causais

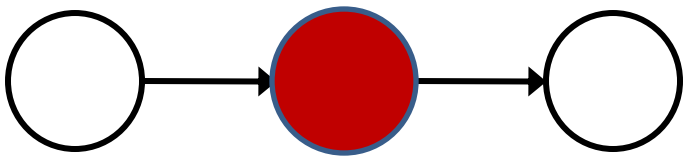

X: Pressão baixa Y: Chuva Z: Tráfego

$$P(x, y, z) = P(x)P(y|x)P(z|y)$$

- X independente de Z dado Y?

$$P(z|x, y) = \frac{P(x, y, z)}{P(x, y)}$$

$$= \frac{P(x)P(y|x)P(z|y)}{P(x)P(y|x)}$$

$$= P(z|y)$$

Sim!

- Evidência na cadeia **bloqueia** a influência

Causa comum

Y: Projeto para casa

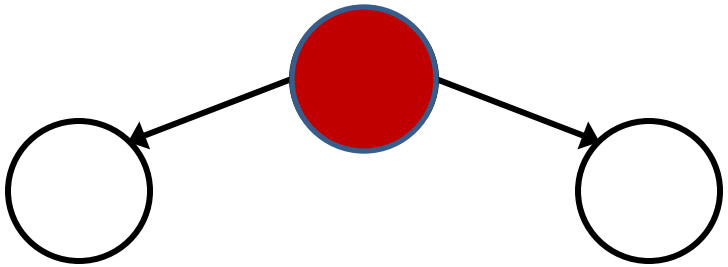

X: Movimentacão do fórum de discussão

Z: Ocupação do laboratório

$$P(x, y, z) = P(y)P(x|y)P(z|y)$$

- X e Z independente dado Y?

$$P(z|x, y) = \frac{P(x, y, z)}{P(x, y)}$$

$$= \frac{P(y)P(x|y)P(z|y)}{P(y)P(x|y)}$$

$$= P(z|y)$$

Sim!

- Observar a causa **bloqueia** influência entre efeitos.

Efeito comum (estruturas v)

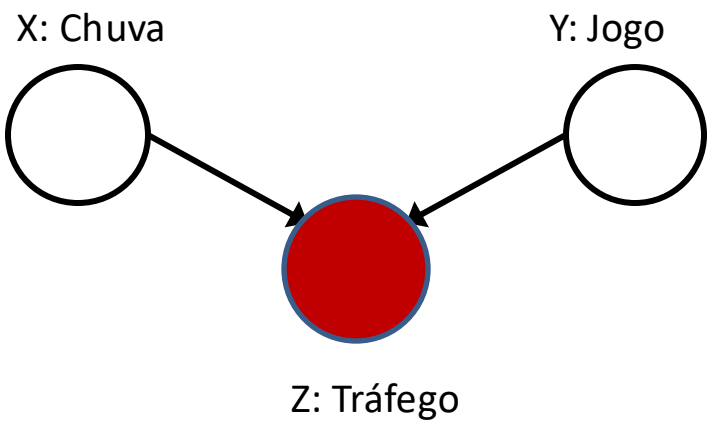

- X e Y independentes?
  - *Sim*: Chuva e Jogo não são relacionados
- X e Y independentes dado Z?
  - *Não*: observar tráfego coloca Chuva e Jogo em competição pela **explicação** do raciocínio
- Observar um efeito **ativa** a influência entre causas possíveis

Caminhos ativos / inativos

- X e Y são condicionalmente independentes dadas as variáveis de evidência {Z}?
  - Sim, se X e Y são **"d-separados"** por Z
  - Dentre todos os caminhos (indiretos) de X à Y, se não houverem caminhos ativos = independência!
- Caminhos ativos:
  - Cadeia causal: $A \rightarrow B \rightarrow C$ com B não observado (qualquer direção)
  - Causa comum: $A \leftarrow B \rightarrow C$ com B não observado
  - Efeito comum: (estrutura v): $A \rightarrow B \leftarrow C$ com B ou um de seus descendentes ser observado

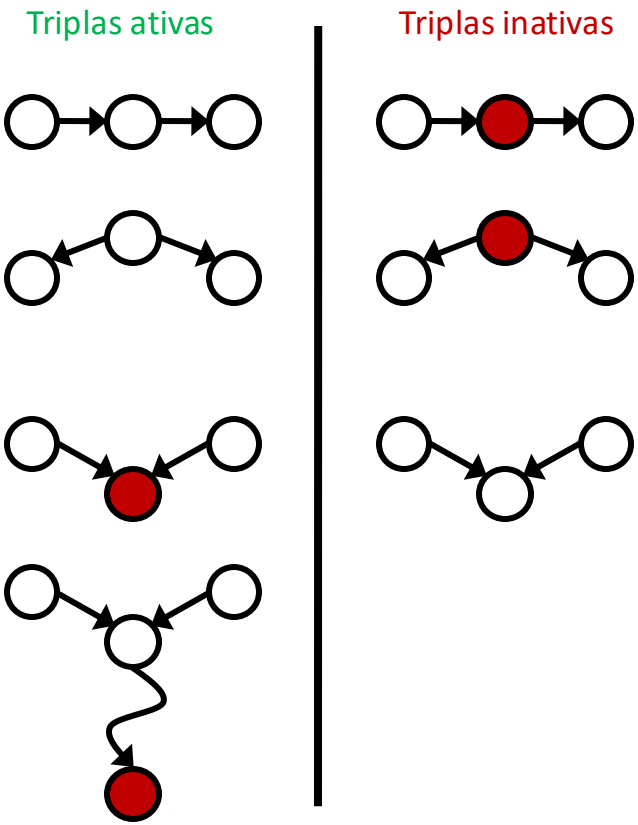

Usando as Redes Bayesianas

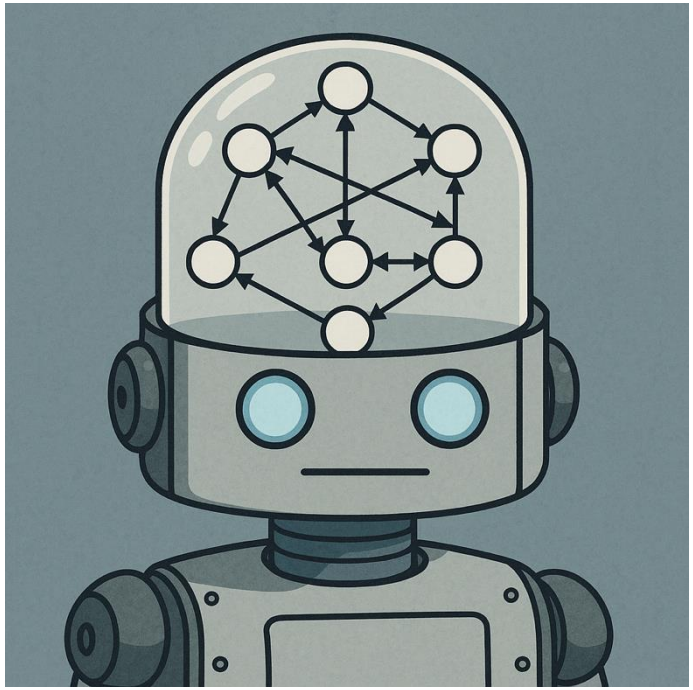

Inferência probabilística

- Processo de calcular a distribuição de probabilidade posterior para variáveis de **consulta (Q)**, dadas as observações de variáveis de **evidência (E)**.
- Ou seja, responder a perguntas da forma:

$$P(Q \mid E = e)$$

- Algoritmo básico: **Inferência Exata por Enumeração**

Inferência exata por Enumeração

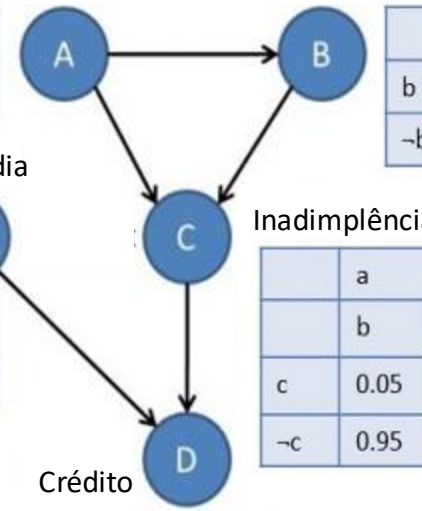

a	0.3
¬a	0.7

	a	¬a
b	0.9	0.4
¬b	0.1	0.6

e	0.35
¬e	0.65

	a		¬a	
	b	**¬b**	b	¬b
c	0.05	**0.5**	0.45	0.6
¬c	0.95	**0.5**	0.55	0.4

	c		¬c	
	e	¬e	e	¬e
d	0.01	0.5	0.75	0.31
¬d	**0.99**	0.5	**0.25**	0.69

$P(a, \neg b, c, \neg d, e) = ?$

Cáculo da probabilidade conjunta:

$P(a, \neg b, c, \neg d, e) = P(a) * P(\neg b|a) * P(c|a, \neg b) * P(\neg d|c, e) * P(e)$

$P(a, \neg b, c, \neg d, e) \ = \ 0.3 * 0.1 * 0.5 * 0.99 * 0.35 \ = 0{,}0051975$ (ou ~0,5%)

Inferência exata por Enumeração

$P(d \mid \neg c, \neg b) = ?$

1. Simplificação (d-separation)

$D \perp B \mid C$ (Cadeia causal – *há evidência*).

$P(d \mid \neg c, \neg b) = \boldsymbol{P(d \mid \neg c)}$

2. Marginalização (Lei da Probabilidade Total)

Introduzimos a variável E (Moradia):

$$P(d \mid \neg c) = \sum_{e} P(d \mid e, \neg c) \cdot \mathbf{P(e \mid \neg c)}$$

3. Simplificação (d-separation)

$E \perp C$ (Efeito comum – *não há evidência*).

$P(e \mid \neg c) = P(e)$

4. Fórmula Final

$$P(d \mid \neg c) = \sum_{e} P(d \mid e, \neg c) \cdot P(e)$$

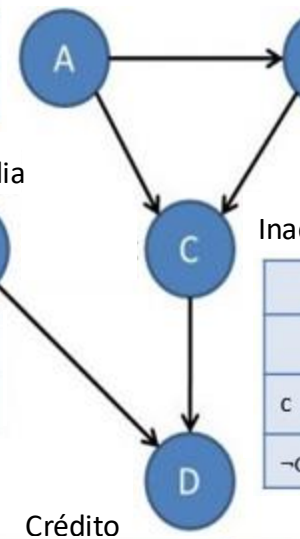

a	0.3
¬a	0.7

	a	¬a
b	0.9	0.4
¬b	0.1	0.6

e	0.35
¬e	0.65

	a		¬a	
	b	**¬b**	b	¬b
c	0.05	**0.5**	0.45	0.6
¬c	0.95	**0.5**	0.55	0.4

	c		¬c	
	e	¬e	e	¬e
d	0.01	0.5	0.75	0.31
¬d	**0.99**	0.5	**0.25**	0.69

5. Cálculo

$P(d \mid \neg c) = P(d \mid e, \neg c)P(e) + P(d \mid \neg e, \neg c)P(\neg e)$

$P(d \mid \neg c) = (0.75 \times 0.35) + (0.31 \times 0.65)$

$P(d \mid \neg c) = 0.2625 + 0.2015$

$\boldsymbol{P(d \mid \neg c) = 0.464}$ **(ou** $\mathbf{46,4\%}$**)**

Inferência exata por Enumeração

$\boldsymbol{P(\neg a \mid e)} = ?$

1. Teorema de Bayes

$$P(\neg a \mid e) = \frac{P(e \mid \neg a) \cdot P(\neg a)}{P(e)}$$

$P(e \mid \neg a) = ?$

2. Simplificação (d-separation)

$A \perp E$ (Efeito comum)

$P(e \mid \neg a) = P(e)$

3. Fórmula Final

$$P(\neg a \mid e) = \frac{P(e) \cdot P(\neg a)}{P(e)}$$

$P(\neg a \mid e) = \boldsymbol{P(\neg a)}$

4. Cálculo

$\boldsymbol{P(\neg a \mid e) = 0.7}$ **(ou 70%)**

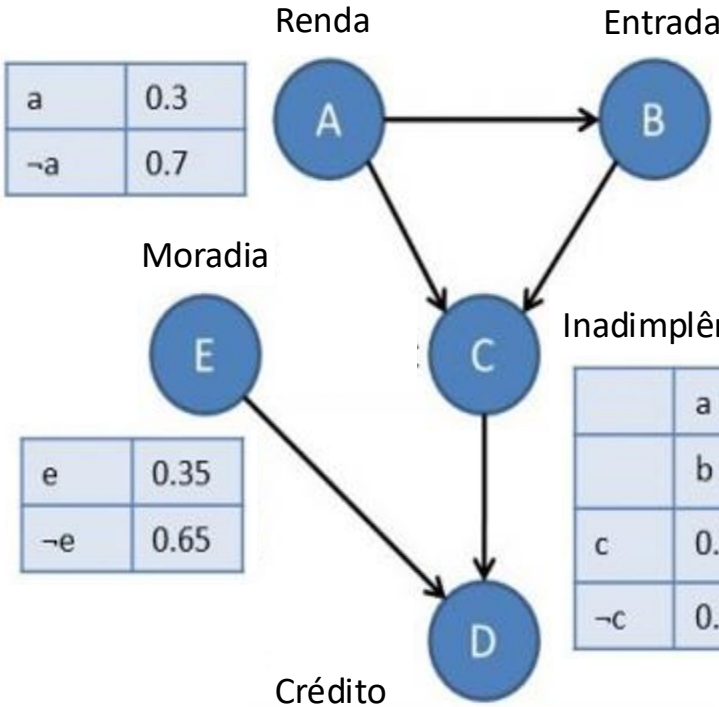

a	0.3
¬a	0.7

	a	¬a
b	0.9	0.4
¬b	0.1	0.6

e	0.35
¬e	0.65

	a		¬a	
	b	**¬b**	b	¬b
c	0.05	**0.5**	0.45	0.6
¬c	0.95	**0.5**	0.55	0.4

	c		¬c	
	e	¬e	e	¬e
d	0.01	0.5	0.75	0.31
¬d	**0.99**	0.5	**0.25**	0.69

Arquitetura de um Agente Probabilista

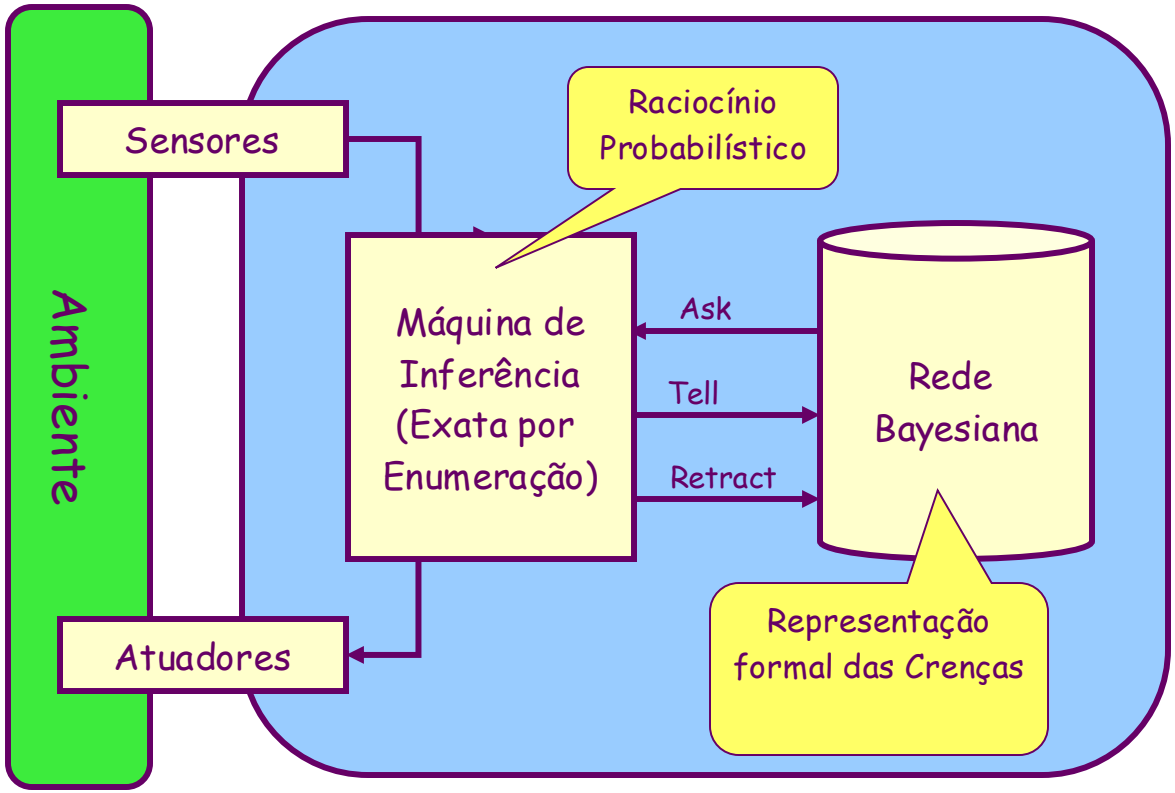

Demo

Selecione a Rede

Escolha uma rede:

Crédito

Navegação

- Topologia da Rede
- Explorar CPTs
- Fazer Inferência

Sobre

Esta aplicação usa o código Python do notebook `bayesian.ipynb` para alimentar uma interface Streamlit interativa.

🧠 Visualizador Interativo de Redes Bayesianas

Uma aplicação para explorar redes Bayesianas e fazer inferências.

Topologia da Rede 'Crédito'

O grafo abaixo mostra as dependências condicionais entre as variáveis.

Topologia Gerada (Graphviz)

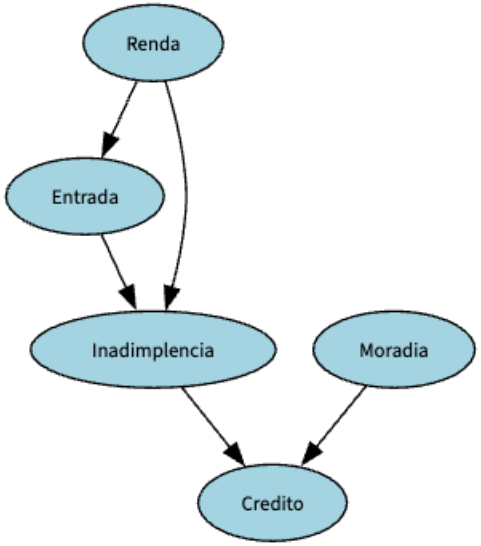

O problema de *Monty Hall*

O problema de *Monty Hall*

A Origem

O Programa de TV *Let's Make a Deal* (rede NBC nos Estados Unidos em 30/12/1963), apresentado por Monty Hall

A Fama

A Coluna de Marilyn vos Savant (1990) (Guinness de maior QI) na revista Parade, sobre enigmas lógicos.

- Carta de Leitor sobre se deveria trocar de porta.
- Resposta de Marilyn: SIM, aumenta chances ara 66,7%.

A Controvérsia

”Maior QI" vs. Especialistas

- Muitas cartas de acadêmicos (estatísticos e doutores em matemática) indignados com a resposta “absurda”

A Redenção

Após muito estudo analítico e simulações, vieram as retratações por parte de todos os críticos!

Marco na história da divulgação científica!

O problema é realmente muito contraintuitivo e **mostra o quão facilmente o cérebro humano (mesmo o de especialistas) pode ser enganado pela probabilidade condicional!**

Outros tópicos sobre BN

- **Outros algoritmos de inferência**
  - **Inferência Exata com Eliminação de Variáveis:** Mais eficiente, explora a estrutura da rede para evitar cálculos redundantes.
  - **Inferência Aproximada:** usada quando a inferência exata é inviável
    - Amostragem de Gibbs (MCMC): Gera um grande número de amostras da rede para estimar as probabilidades.
- **Gerando uma BN a partir de dados**
  - **Aprendizado de Parâmetros:**
    - Estimativa de Máxima Verossimilhança (Maximum Likelihood Estimation - MLE)
  - **Aprendizado de Estrutura:**
    - Baseada em Pontuação (Score-based)
      - Usa algoritmos de busca heurística (como hill-climbing)
    - Baseada em Restrições (Constraint-based)
- **Modelos de aprendizado de máquina para classificação**
  - **Naïve Bayes**

Paralelos sobre técnicas de raciocínio

- Raciocínio Lógico || Redes Bayesianas
  - Estrutura do conhecimento || crença
- Backward Chaining || Inferência por Enumeração
  - Algoritmos de inferência

Aspectos Éticos

Explicabilidade

- Muitos modelos de IA, como Redes Neurais Profundas, são **"caixas-pretas" (black-box)**. São precisos, mas sua lógica interna é inescrutável.
- Redes Bayesianas são modelos **"caixa-branca" (white-box)** ou "caixa-cinza".
- Sua transparência vem de:
  - **Estrutura Explícita:** O DAG é uma representação visual das suposições do modelo, auditável por especialistas.
  - **Quantificação da Incerteza:** A saída é uma distribuição de probabilidade, que comunica o grau de confiança do modelo.

Vieses

- **Viés de Amostragem:** grupos demográficos sub-representados nos dados estão sujeitos a estimativas de probabilidade menos precisas e com maior ruído estatístico. O modelo pode ter um desempenho significativamente pior para grupos minoritários.
- **Viés Histórico:** dados podem refletir preconceitos sociais passados. Por exemplo, um modelo de contratação de uma empresa que historicamente contratou poucos engenheiros do sexo feminino, vai exibir uma correlação espúria entre ser do sexo masculino e ser um candidato qualificado, mesmo que o gênero não seja uma variável explícita no modelo.
- **Correlações Espúrias:** A estrutura dos dados pode induzir dependências estatísticas entre atributos protegidos (como raça, gênero) e o resultado de interesse, mesmo que não haja uma relação causal real. Por exemplo, em muitas cidades, o código postal (CEP) está fortemente correlacionado com a composição racial de um bairro. Um modelo de risco de crédito que usa o CEP como uma variável pode, indiretamente, discriminar com base na raça, mesmo que a raça não seja um input. A BN aprenderá uma CPT que atribui diferentes probabilidades de inadimplência a diferentes CEPs, efetivamente replicando o viés sistêmico.

Privacidade

- A mesma estrutura que torna as Redes Bayesianas explicáveis também pode criar vulnerabilidades de privacidade. A principal preocupação é o risco de **Inferência de Atributos**. Este tipo de ataque ocorre quando um **adversário (cibercriminoso/anunciante/etc.) usa informações publicamente disponíveis sobre um indivíduo para inferir atributos privados e sensíveis** que não foram compartilhados diretamente.
- As BNs são particularmente relevantes para este risco porque elas **modelam explicitamente as dependências probabilísticas entre as variáveis**. A estrutura do grafo e as CPTs quantificam exatamente o quão fortemente o conhecimento de uma variável (e.g., os "likes" de um usuário em redes sociais) informa sobre outra variável (e.g., sua afiliação política ou orientação sexual).
- Considere um adversário que tenha acesso a um modelo BN treinado (ou que possa reconstruí-lo a partir de dados públicos) e a alguns dados não sensíveis sobre um alvo. O processo de ataque seria:
  - O adversário insere os dados públicos conhecidos sobre o alvo como evidência na BN.
  - Realiza então uma inferência para calcular a distribuição de probabilidade a posteriori sobre o nó do atributo sensível que deseja descobrir.
  - Se a probabilidade posterior para um determinado estado do atributo sensível for alta, o adversário pode inferir essa informação com um alto grau de confiança.
- A Transparência da BN, que é uma vantagem para a explicabilidade, torna-se uma desvantagem para a privacidade. O **grafo atua como um "mapa" para o adversário, mostrando-lhe os caminhos de inferência mais promissores** — as correlações mais fortes que ele pode explorar. Isso é particularmente preocupante porque **técnicas de anonimização simples, como a remoção de identificadores diretos (nome, CPF), são ineficazes contra ataques de inferência de atributos**. A proteção contra tais riscos requer técnicas de privacidade mais avançadas, como a Privacidade Diferencial, que adiciona ruído cuidadosamente calibrado aos dados ou aos resultados do modelo para tornar matematicamente difícil inferir informações sobre qualquer indivíduo específico.

Dúvidas?

"Livros não mudam o mundo, quem muda o mundo são as pessoas. Os livros só mudam as pessoas."

— Mario Quintana

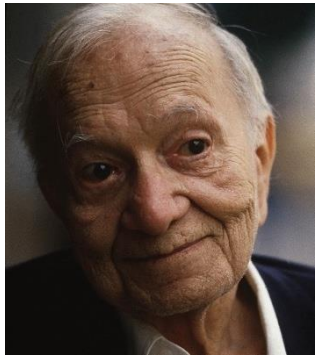

- [AIMA] RUSSELL, Stuart J.; NORVIG, Peter. Artificial Intelligence: A Modern Approach. 4. ed. Global Edition. Harlow: Pearson, 2021.
  - Capítulos 12 e 13
- [Website Hendrik] https://hendrikdcomp.github.io/ia/