Modelos de Linguagem

Prof. Dr. Hendrik Macedo
Departamento de Computação

Quando os modelos são generativos

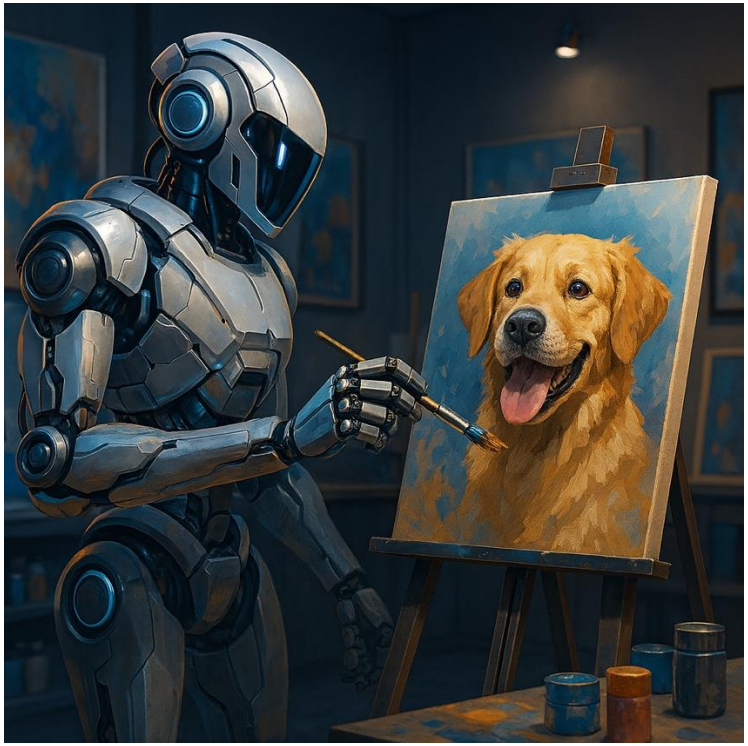

Modelos Discriminativos

- Focam em **limites de decisão** para separar classes.
- Modelam a **probabilidade condicional**:

$$P(Classe|Dados)$$

ID	Animal (Nome)	eggs?	fly?	feathers?	Class
1	Sparrow (Pardal)	True	True	True	Bird
2	Eagle (Águia)	True	True	True	Bird
3	Parrot (Papagaio)	True	True	True	Bird
4	Penguin (Pinguim)	True	False	True	Bird
5	Ostrich (Avestruz)	True	False	True	Bird
6	Bat (Morcego)	False	True	False	Mammal
7	Dog (Cachorro)	False	False	False	Mammal
8	Cat (Gato)	False	False	False	Mammal
9	Pigeon (Pombo)	True	True	True	Bird
10	Elephant (Elefante)	False	False	False	Mammal
11	Hawk (Falcão)	True	True	True	Bird
12	Lion (Leão)	False	False	False	Mammal
13	Kiwi (Kiwi)	True	False	True	Bird
14	Whale (Baleia)	False	False	False	Mammal
15	Platypus (Ornitorrinco)	True	False	False	Mammal

modelo

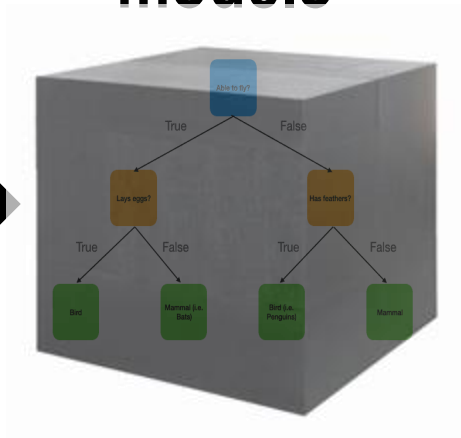

$$P(Bird?|True, False, True)$$

Modelos Generativos

- Focam na **distribuição dos dados**
- Modelam a **probabilidade conjunta**:

$$P(Dados, Classe) \text{ ou } P(Dados).$$

- Assume um processo de geração:

$$P(Classe) \rightarrow P(Dados|Classe)$$

ID	Animal (Nome)	eggs?	fly?	feathers?	Class
1	Sparrow (Pardal)	True	True	True	Bird
2	Eagle (Águia)	True	True	True	Bird
3	Parrot (Papagaio)	True	True	True	Bird
4	Penguin (Pinguim)	True	False	True	Bird
5	Ostrich (Avestruz)	True	False	True	Bird
6	Bat (Morcego)	False	True	False	Mammal
7	Dog (Cachorro)	False	False	False	Mammal
8	Cat (Gato)	False	False	False	Mammal
9	Pigeon (Pombo)	True	True	True	Bird
10	Elephant (Elefante)	False	False	False	Mammal
11	Hawk (Falcão)	True	True	True	Bird
12	Lion (Leão)	False	False	False	Mammal
13	Kiwi (Kiwi)	True	False	True	Bird
14	Whale (Baleia)	False	False	False	Mammal
15	Platypus (Ornitorrinco)	True	False	False	Mammal

modelo

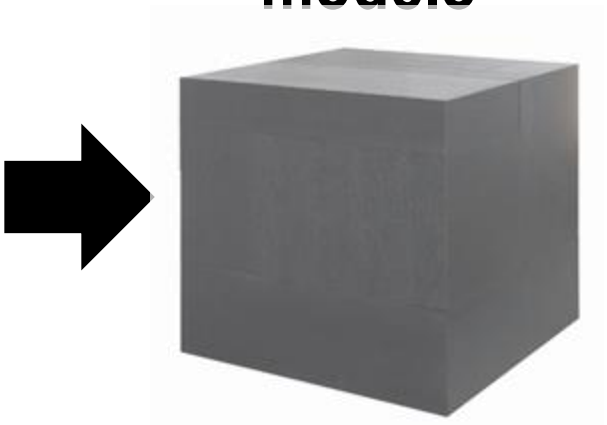

$$P(True, False, True|Bird)$$

Modelos discriminativos vs generativos

Modelos discriminativos

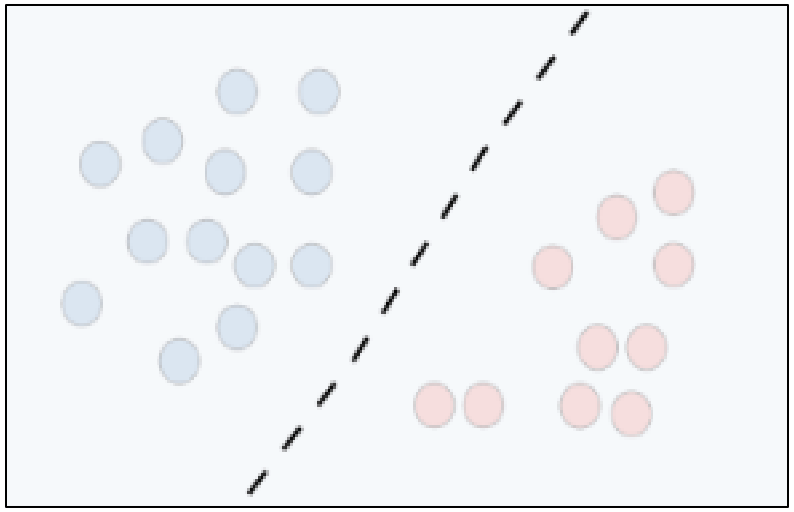

Modelos generativos

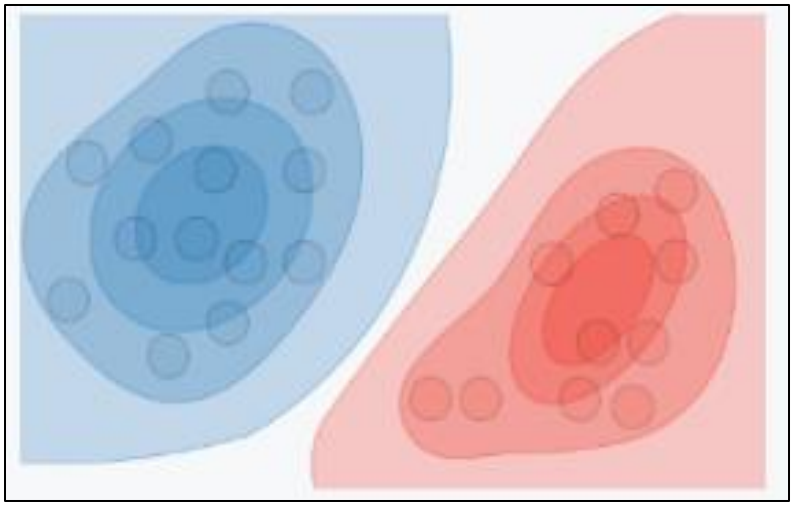

Sobre como a máquina representa a linguagem humana

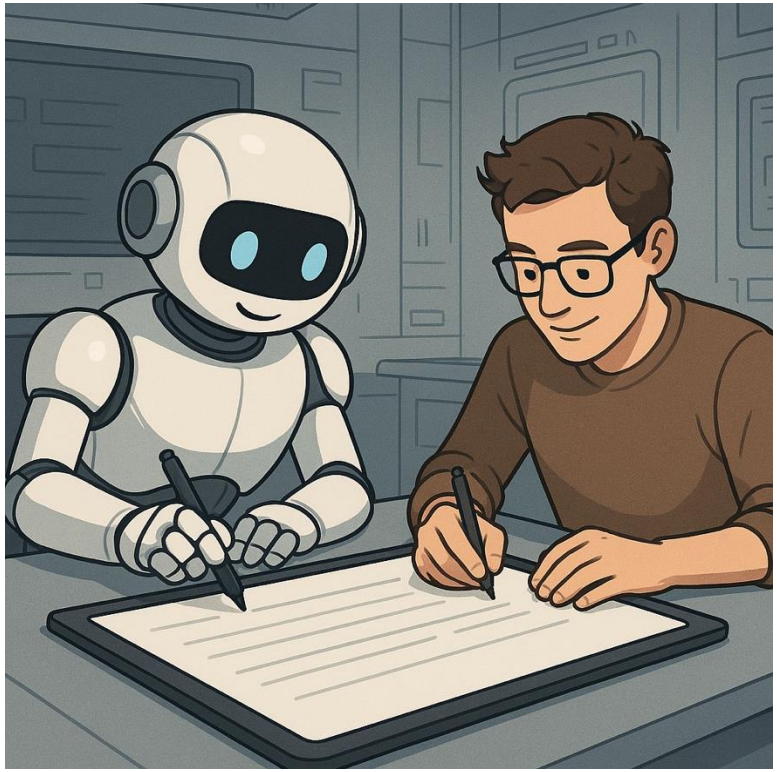

Fundamentos do N-Gram

- A forma mais simples de Modelo de Linguagem estatístico.
- Regra da Cadeia da Probabilidade: a probabilidade de uma sentença inteira W é o produto das probabilidades condicionais:
  - $\mathrm{P}(w_1, \dots, w_m) = P(w_1) \cdot P(w_2|w_1) \cdot P(w_3|w_1, w_2) \cdot \dots \cdot P(w_m|w_1, \dots, w_{m-1})$
- Hipótese de Markov (ordem $N - 1$): simplificação crucial
  - Assume que a próxima palavra w_i depende apenas das $N - 1$ palavras imediatamente anteriores, e não de todo o histórico
  - $\mathrm{P}(w_i|w_1, \dots, w_{i-1}) \approx P\left(w_i \middle| w_{i-(N-1)}, \dots, w_{i-1}\right)$

A ordem do Contexto

- **Unigrama** ($N = 1$): Palavras são independentes.
$$P(w_i)$$
- **Bigrama** ($N = 2$): Dependência da palavra anterior.
$$P(w_i|w_{i-1})$$
- **Trigrama** ($N = 3$): Dependência das duas anteriores.
$$P(w_i|w_{i-2}, w_{i-1})$$
- **Tokenização especial**: o uso de *pseudo-palavras* $\langle s \rangle$ e $\langle /s \rangle$ marca o início e o fim da sentença para garantir que o contexto inicial e final seja completo

A ordem do Contexto

- Unigramas (N=1): Frequência de palavras isoladas

$$\langle s \rangle$$
$$O$$
$$cão$$
$$late$$
$$\langle /s \rangle$$

- Bigramas (N=2): Sequências de duas palavras adjacentes

$$\langle s \rangle\ O$$
$$\text{O}\ cão$$
$$\text{cão}\ late$$
$$\text{late}\ \langle /s \rangle$$

Treinamento do modelo

- **Estimativa de Máxima Verossimilhança (MLE)**
  - Calcula a probabilidade da palavra w_i dado a palavra anterior w_{i-1} (Bigrama), usando a razão entre a contagem do Bigrama e a contagem do Contexto (Unigrama).

$$\mathrm{P}(w_i|w_{i-1}) = \frac{\mathrm{C}(w_{i-1}, w_i)}{\mathrm{C}(w_{i-1})}$$

Treinamento do modelo

- **Estimativa de Máxima Verossimilhança (MLE)**
  - Envolve contar frequências de N-grams no ***corpus*** e normalizá-las.

$$\mathrm{P}(w_i|w_{i-1}) = \frac{\mathrm{C}(w_{i-1}, w_i)}{\mathrm{C}(w_{i-1})}$$

Corpus

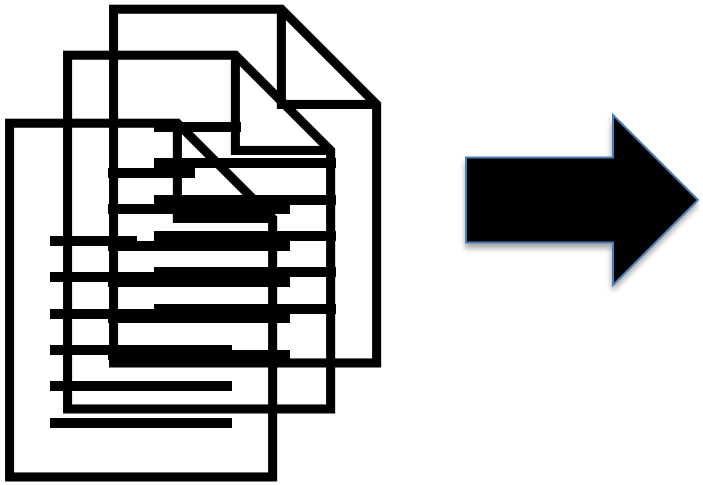

Bigrama	Contagem
Eu gosto	12
gosto de	10
gosto muito	2
gosto é	1
Eu não	8

Treinamento do modelo

- **Estimativa de Máxima Verossimilhança (MLE)**
  - Envolve contar frequências de N-grams no ***corpus*** e normalizá-las.

$$P(w_i|w_{i-1}) = \frac{C(w_{i-1}, w_i)}{C(w_{i-1})}$$

Corpus

Bigrama	**Contagem**
Eu gosto	12
gosto de	10
gosto muito	2
gosto é	1
Eu não	8

$$P(\text{gosto}|\text{Eu}) = \frac{C(\text{Eu gosto})}{C(\text{Eu})}$$

$$P(\text{gosto}|\text{Eu}) = \frac{12}{20} = 0.60$$

$$P(\text{muito}|\text{gosto}) = \frac{C(\text{gosto muito})}{C(\text{gosto})}$$

$$P(\text{muito}|\text{gosto}) = \frac{2}{13} \approx 0.154$$

Treinamento do modelo

Corpus

Bigrama	**Contagem**
Eu gosto	12
gosto de	10
gosto muito	2
gosto é	1
Eu não	8

$$\mathrm{P}(\text{gosto}|\text{Eu}) = \frac{\mathrm{C}(\text{Eu gosto})}{\mathrm{C}(\text{Eu})}$$

$$\mathrm{P}(\text{gosto}|\text{Eu}) = \frac{12}{20} = 0.60$$

$$\mathrm{P}(\text{muito}|\text{gosto}) = \frac{\mathrm{C}(\text{gosto muito})}{\mathrm{C}(\text{gosto})}$$

$$\mathrm{P}(\text{muito}|\text{gosto}) = \frac{2}{13} \approx 0.154$$

Normalização: A divisão pela contagem do contexto (denominador) garante que a soma das probabilidades de todas as palavras que podem seguir um contexto específico ($\mathrm{C}(\text{gosto})$) resulte em 1.

$$\mathrm{P}(\text{de}|\text{gosto}) + \mathrm{P}(\text{muito}|\text{gosto}) + \mathrm{P}(\text{é}|\text{gosto}) + \cdots \approx \frac{10}{13} + \frac{2}{13} + \frac{1}{13} + \cdots = 1$$

Uso do modelo

Bigrama	**C($w_{i-1}w_i$)**	**C(w_{i-1})**	$P(w_i \mid w_{i-1})$
$\langle s \rangle$ Eu	10	20	10 / 20 = 0.50
Eu gosto	12	20	12 / 20 = 0.60
Eu não	8	20	8 / 20 = 0.40
gosto de	10	13	10 / 13 ≈ 0.77
gosto muito	2	13	2 / 13 ≈ 0.15
não gosto	8	15	8 / 15 ≈ 0.53
de você	5	10	5 / 10 = 0.50
muito $\langle /s \rangle$	1	1	1 / 1 ≈ 1.00
você $\langle /s \rangle$	3	5	$3/5 = 0.60$

Uso do modelo

- A probabilidade de uma sequência W é o produto das probabilidades condicionais de Bigrama (MLE):

$$\mathrm{P}(W) = P(w_1|\langle s\rangle) \cdot P(w_2|w_1) \cdot P(w_3|w_2) \cdot \ldots \cdot P(\langle /s\rangle|w_m)$$

$$\mathrm{MLE} = 0.50 \cdot 0.60 \cdot 0.77 \cdot 0.50 \cdot 0.60 \approx 0.0693$$

Sequência: "$\langle s\rangle$ Eu gosto → de você $\langle /s\rangle$"

Sequência: "$\langle s\rangle$ Eu gosto → muito $\langle /s\rangle$"

$$\mathrm{MLE} = 0.50 \cdot 0.60 \cdot 0.15 \cdot 1.00 \approx 0.0450$$

Tokenização

- Palavras vs. Tokens

"O futuro da IA em PLN (Processamento de Linguagem Natural) baseia-se em arquiteturas neurais que superam as limitações de contexto fixo e escassez de dados herdadas dos N-Grams."

→ tokenização do GPT

```
O futuro da IA em PLN (Processamento de Linguagem Natural) base
ia-se em arquiteturas neurais que superam as limitações de
 contexto fixo e escassez de dados herdadas dos N-Grams.
```

Tokenização

```
O futuro da IA em PLN (Processamento de Linguagem Natural) baseia-se em arquiteturas neurais que superam as limitações de contexto fixo e escassez de dados herdadas dos N-Grams.
```

```
[46, 28600, 1033, 59199, 863, 177082, 350, 7212, 4626, 334, 126554, 8551, 23735, 8, 3611, 535, 5460, 863, 123148, 12558, 36501, 1873, 661, 2539, 313, 472, 117731, 4693, 334, 50124, 9295, 78, 319, 4575, 5788, 89, 334, 24315, 94705, 3921, 3406, 478, 85061, 2247, 2517]
```

Embeddings (representação vetorial)

```
[46, 28600, 1033, 59199, 863, 177082, 350, 7212, 4626, 334, 126554, 8551,
23735, 8, 3611, 535, 5460, 863, 123148, 12558, 36501, 1873, 661, 2539,
313, 472, 117731, 4693,                                  5, 5788, 89, 334,
24315, 94705, 3921, 3406
```

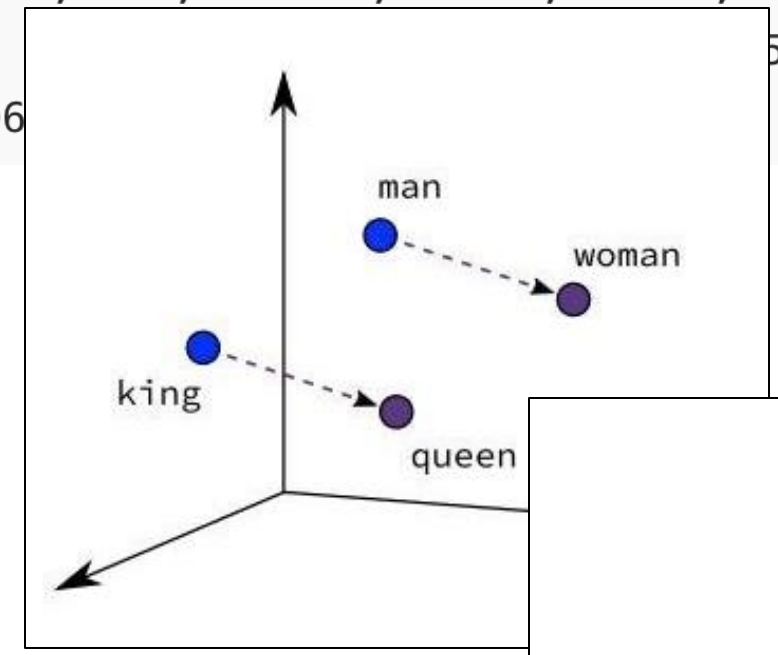

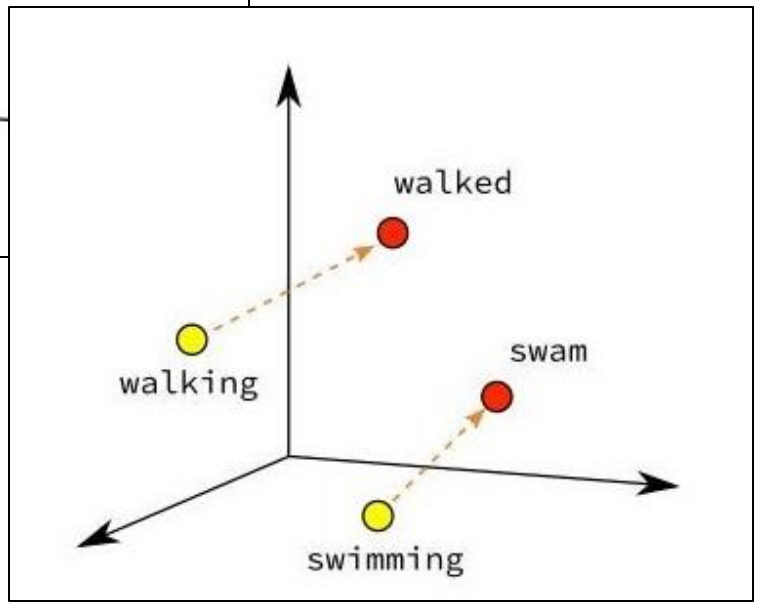

embeddings

O	futuro	...	arquitet
0.9	3.0		-1.0
-1.2	-0.4		0.7
.	.		.
.	.		.
.	.		.
.	.		.
0.1	5.1		-0.3

Transformer

Vaswani, Ashish, et al. **"Attention is all you need."** *Advances in neural information processing systems* 30 (2017).

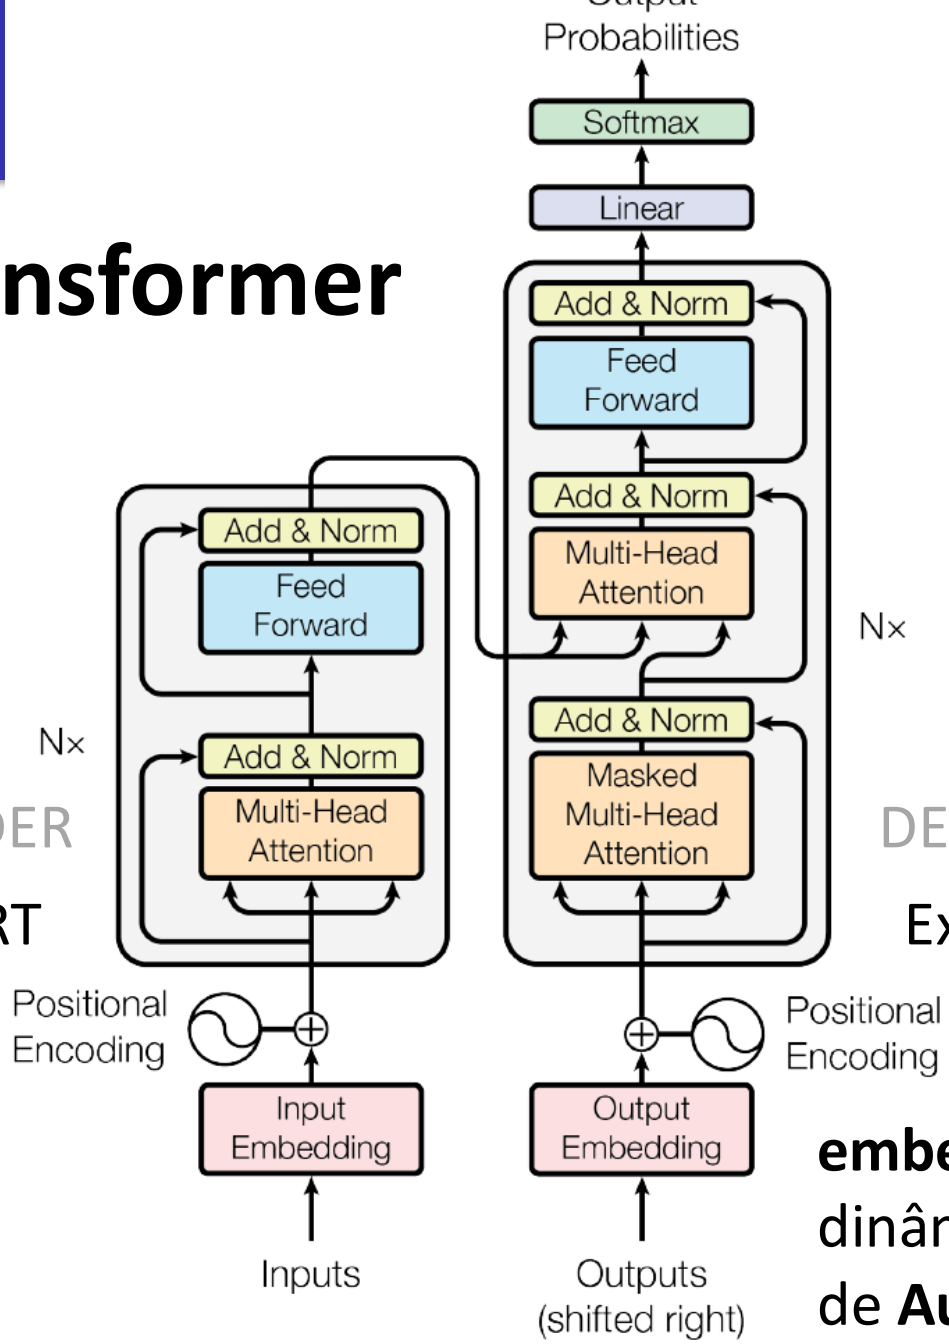

ENCODER

Ex: BERT

DECODER

Ex: GPT

embeddings contextuais (ou dinâmicos) através do mecanismo de **Auto-Atenção** (*Self-Attention*)

Transformer

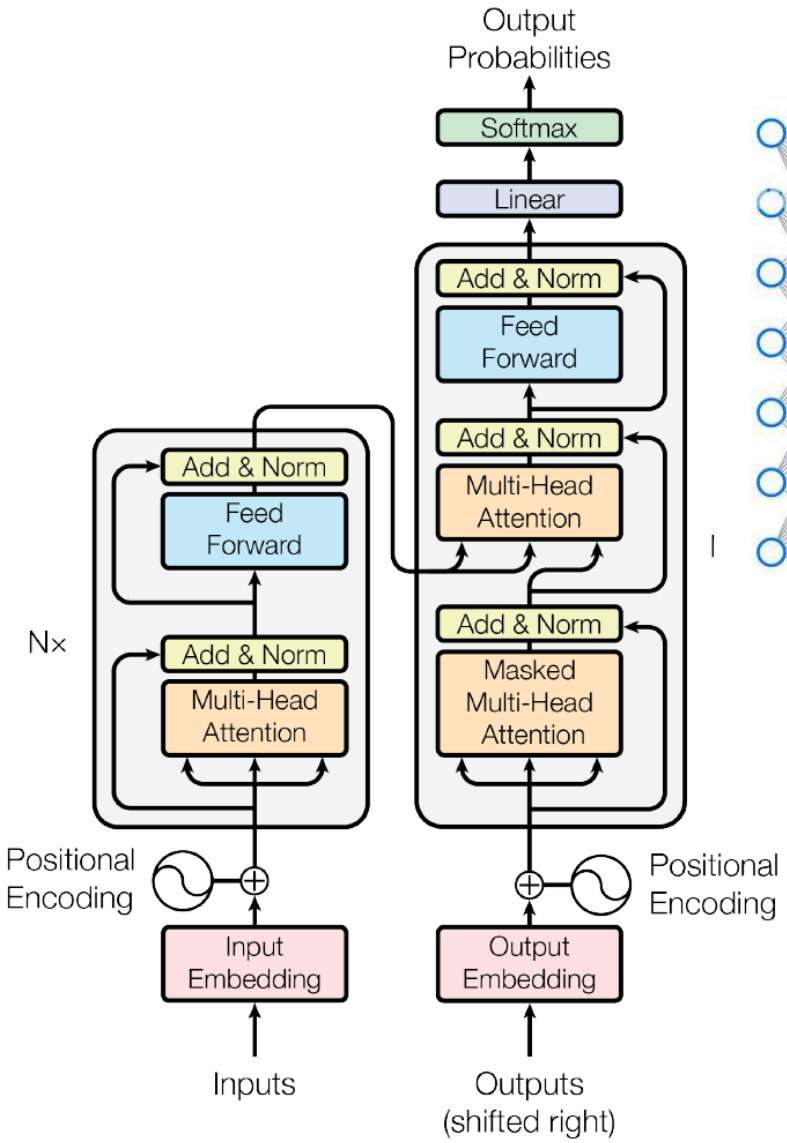

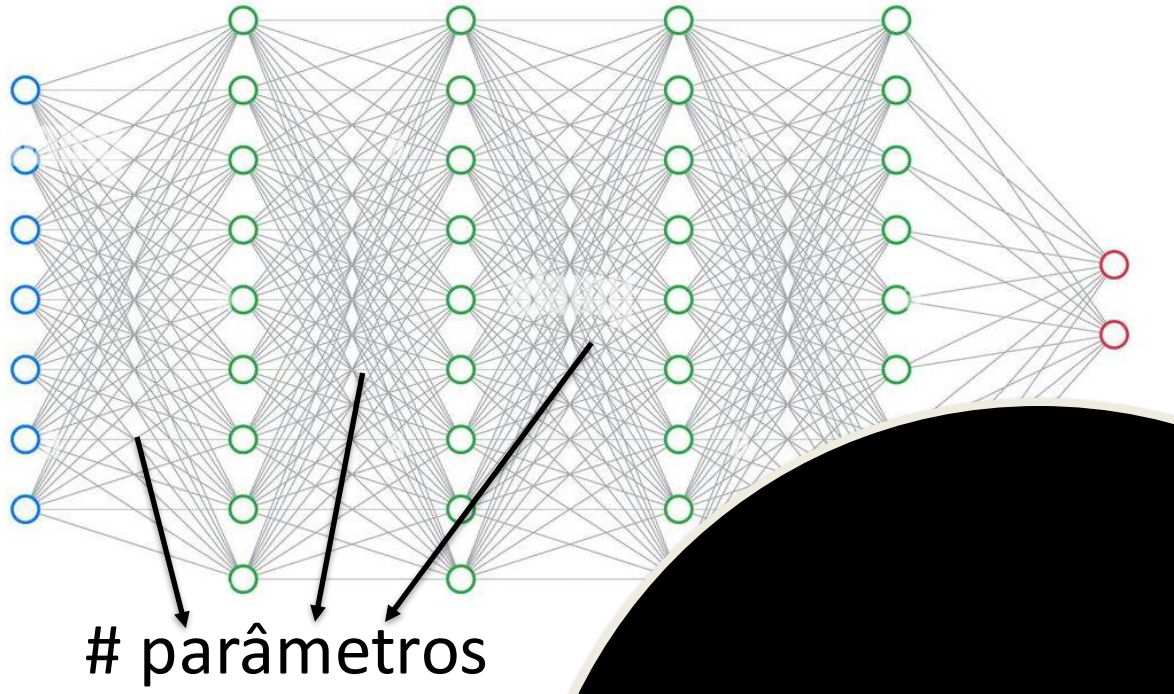

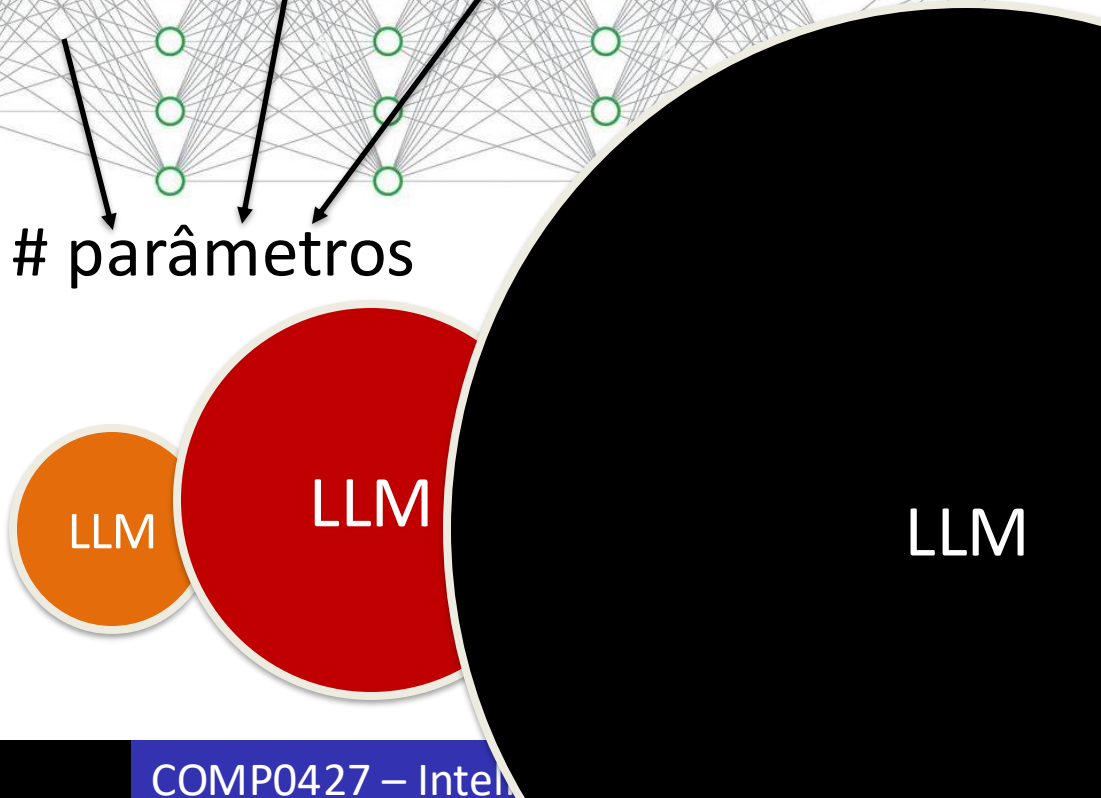

Aplicações dos modelos de linguagem

Classes de aplicação

I. **Aplicações Preditivas e de Assistência Linguística**: tarefas nas quais os modelos usam a prob. de seq. para melhorar a precisão em ambientes ruidosos ou ambíguos

   a. Reconhecimento de fala
   b. Correção ortográfica e gramatical
   c. Previsão de Texto (autocomplete)
   d. Tradução de Máquina
   e. Text-to-Speech (TTS)

Classes de aplicação

II. **Classificação e Análise de Conteúdo:** os N-Grams são extraídos como *features* robustas para alimentar classificadores

   a. *Análise de Sentimento*
   b. Classificação de Texto
   c. Perfilamento
   d. Filtro de Spam e Detecção de Fraude
   e. Identificação de Idioma

Classes de aplicação

II. **Tarefas avançadas de Geração e Raciocínio:** com o *Transformer*, as capacidades dos modelos se expandiram exponencialmente

a. Geração de Texto (texto, código, etc.)

b. Resumo de Texto (*summarization*)

c. Agentes Conversacionais (*Chatbots*)

d. Recuperação de informação e raciocínio em *corpora*

Análise de Sentimento

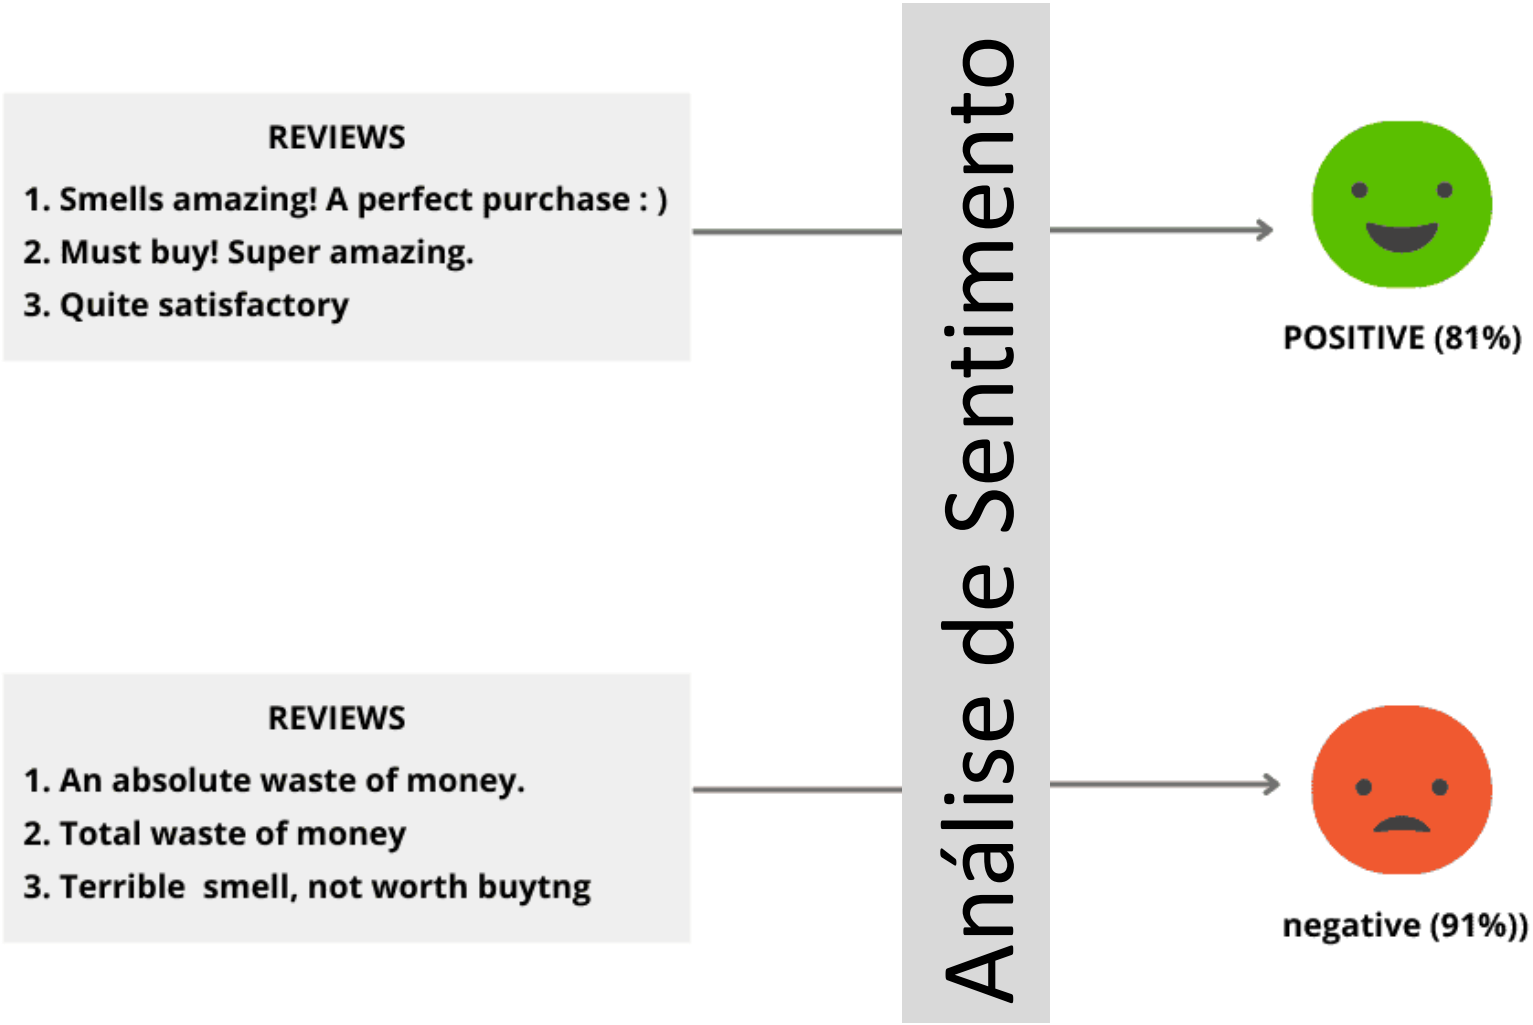

Análise de Sentimento

- **Naïve Bayes:** classificador **generativo** clássico
  - Modela como o documento *d* é gerado dada a classe *c*

$P(C)$

```
pos: 0.66
neg: 0.33
```

$P(palavra|neg)$

```
the :  0.0156
to  :  0.0153
and :  0.0115
of  :  0.0095
you :  0.0093
a   :  0.0086
with:  0.0080
from:  0.0075
...
```

$P(palavra|pos)$

```
the :  0.0210
to  :  0.0133
of  :  0.0119
2002:  0.0110
with:  0.0108
from:  0.0107
and :  0.0105
a   :  0.0100
...
```

Análise de Sentimento com Naïve Bayes

- O classificador busca a classe $\hat{c}$ que maximiza a probabilidade a posteriori $P(c|d)$

$$\hat{c} = \text{argmax}_{c \in C} P(c|d) = \text{argmax}_{c \in C} P(d|c)P(c)$$

]Teorema de Bayes]

Análise de Sentimento com Naïve Bayes

$$\hat{c} = \text{argmax}_{c \in C} P(d|c)P(c)$$

- Modelo assume (**ingenuamente**) que as *features* (palavras f_i (são **condicionalmente independentes** dada a classe c

$$\mathrm{P}(f_1, f_2, \ldots, f_n|c) = \prod_{i=1}^{n} P(f_i|c)$$

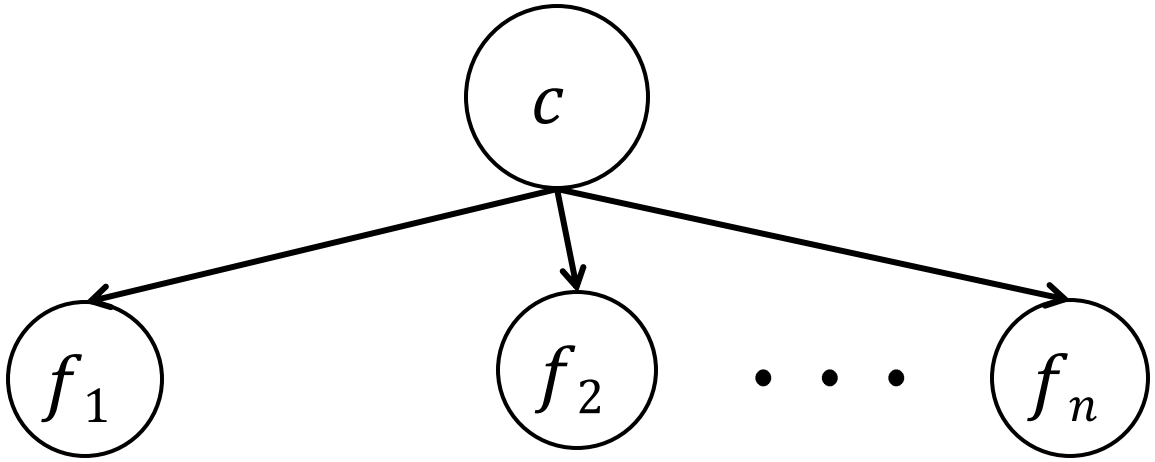

Dúvidas?

"Livros não mudam o mundo, quem muda o mundo são as pessoas. Os livros só mudam as pessoas."

— Mario Quintana

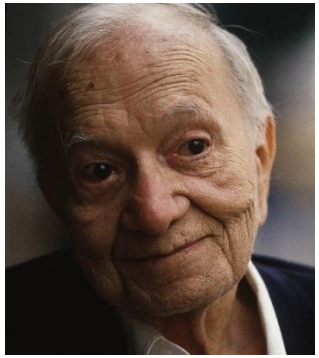

- [AIMA] RUSSELL, Stuart J.; NORVIG, Peter. Artificial Intelligence: A Modern Approach. 4. ed. Global Edition. Harlow: Pearson, 2021.
  - Seção 12.6 (Naïve Bayes)
  - Seção 24.1 (N-Gram / PLN)
  - <u>*Opcional:*</u>
    - Seção 25.1 (*Embeddings*)
    - Seção 25.4 (*Transformer*)